

哈尔滨工业大学

模式识别与机器学习实验报告

实验 二

题	目	逻辑回归
学	院	未来技术学院
专	业	人工智能
学	号	2023112419
学	生	陈铠
任	课 教 师	刘扬

哈尔滨工业大学计算机科学与技术学院

2025 年秋季

一、实验内容

(一) 逻辑回归简要介绍

逻辑回归 (Logistic Regression) 是以二分类为主的判别式、监督学习的分类模型。

1 逻辑回归的核心任务

逻辑回归的核心任务是针对输入的特征向量 $\mathbf{x} \in \mathbb{R}^d$ 学习映射关系：

$$f(\mathbf{x}; \theta): \mathbb{R}^d \rightarrow [0, 1]$$

通过学习数据特征，建立拟合函数 $f(\mathbf{x}; \theta)$ 来估计后验概率 $P(y = 1 | \mathbf{x})$ ，再基于概率阈值判别最终类别 y 。

在本实验中，主要研究逻辑回归的**线性二分类**问题。而事实上，也可以将逻辑回归算法拓展更广泛的问题上，例如通过对特征进行非线性映射，可以学习到非线性决策边界；通过设计 One-vs-Rest 或 Softmax 回归，可以实现多分类问题。

2 逻辑回归的数学模型

逻辑回归选用的拟合函数为

$$h_{\theta}(\mathbf{x}) = g(\theta^T \mathbf{x}) = \frac{1}{1 + e^{-\theta^T \mathbf{x}}}$$

其中 $g(x)$ 为 sigmoid 函数。 $\theta^T \mathbf{x} = \sum_{i=0}^n \theta_i x_i, x_0 = 1$ 。

对于待分类样本，有 $\hat{y} = \mathbb{I}[\theta^T \mathbf{x} \geq 0]$

3 逻辑回归的优化方法

3.1 符号定义

表 1 本实验使用符号

名称	符号	描述
特征矩阵	$X \in \mathbb{R}^{m \times n}$	每行 $\mathbf{x}^{(i)} \in \mathbb{R}^n$ 为第 i 个样本，含 n 个特征（常置第一个特征为 1）
输出向量	$\mathbf{y} \in \mathbb{R}^m$	每行 $y^{(i)}$ 为第 i 个样本的预测值（0 或 1）
参数向量	$\theta \in \mathbb{R}^n$	模型待优化变量
预测向量	$\mathbf{h} \in \mathbb{R}^m$	每行 $h_i = h_{\theta}(\mathbf{x}^{(i)})$

记训练集为 $\{(\mathbf{x}^{(i)}, y^{(i)})\}_i^m$ 且样本独立同分布，使用极大似然估计 MLE 以及交叉熵损失，可以得到

$$L(\theta) = P(\mathbf{y} | \mathbf{X}; \theta) = \prod_{i=1}^m p(y^{(i)} | \mathbf{x}^{(i)}; \theta) = \prod_{i=1}^m (h_{\theta}(\mathbf{x}^{(i)}))^{y^{(i)}} (1 - h_{\theta}(\mathbf{x}^{(i)}))^{1-y^{(i)}}$$

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^m y^{(i)} \log h(\mathbf{x}^{(i)}) + (1 - y^{(i)}) \log (1 - h(\mathbf{x}^{(i)}))$$

于是损失函数为

$$J(\theta) = -\frac{1}{m}[y^T \log h + (1-y)^T \log (1-h)] + \frac{\lambda}{2m} \theta^T \theta$$

其中 $\frac{\lambda}{2m} \theta^T \theta$ 为正则化项

模型的训练目标是

$$\theta^* = \underset{\theta}{\operatorname{argmin}} J(\theta)$$

3.2 梯度下降法求解

梯度下降核心是求解损失函数梯度向量 $\nabla J(\theta) \in \mathbb{R}^n$ ，再沿负梯度方向更新参数
单个参数的偏导数为

$$\frac{\partial}{\partial \theta_j} J(\theta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)} + \frac{\lambda}{m} \theta_j$$

于是

$$\nabla J(\theta) = -\frac{1}{m} X^T (y - h) + \frac{\lambda}{m} \theta$$

更新公式为

$$\begin{aligned} \theta^{(t+1)} &= \theta^{(t)} - \alpha \cdot \nabla J(\theta^{(t)}) \\ &= \theta^{(t)} - \alpha \left[-\frac{1}{m} X^T (y - h^{(t)}) + \frac{\lambda}{m} \theta^{(t)} \right] \\ &= \theta^{(t)} + \frac{\alpha}{m} X^T (y - h^{(t)}) - \frac{\alpha \lambda}{m} \theta^{(t)} \end{aligned}$$

其中 $\frac{\alpha \lambda}{m} \theta^{(t)}$ 为正则项。

3.3 牛顿法求解

牛顿法使用二阶导数矩阵 Hessian 矩阵 $H \in \mathbb{R}^{n \times n}$ 加速收敛

$$H = \frac{1}{m} X^T D X + \frac{\lambda}{m} I$$

其中 $D \in \mathbb{R}^{m \times m}$ 是对角矩阵，对角元素 $D_{ii} = h_i(1-h_i)$ ， $I \in \mathbb{R}^{n \times n}$ 是单位矩阵
更新公式为

$$\begin{aligned} \theta^{(t+1)} &= \theta^{(t)} - H^{-1} \nabla J(\theta^{(t)}) \\ &= \theta^{(t)} - \left(\frac{1}{m} X^T D^{(t)} X + \frac{\lambda}{m} I \right)^{-1} \left[-\frac{1}{m} X^T (y - h^{(t)}) + \frac{\lambda}{m} \theta^{(t)} \right] \end{aligned}$$

其中 $\frac{\lambda}{m} I$ ， $\frac{\lambda}{m} \theta^{(t)}$ 为正则项。

(二) 实验研究内容

1 研究样本数量、样本分布条件的影响

调整样本数量为 100, 200, 类朴素贝叶斯分布与不满足类朴素贝叶斯分布。

2 研究两种求解方法和正则化的影响,

分别为：梯度下降+无正则化、梯度下降+正则化、牛顿方法+无正则化、牛顿方法+正则化。

3 研究模型在真实数据上的分类表现

使用 UCI 数据集（<https://archive.ics.uci.edu/dataset/267/banknote+authentication>）。共 1372 个样本，特征维度为 4，类别为 2

二、 实验环境

操作系统：Windows 11

实验平台：pycharm

解释器版本：Python 3.12

工具包：

表 2 本实验使用工具包

工具包名称	版本
pip	25.2
matplotlib	3.10.6
numpy	2.3.3
scikit-learn	1.7.2

三、 实验结果及分析

（一）样本数量、样本分布条件的影响

在该项中选用梯度下降+无正则化的求解方法




图 1-4 样本数量、样本分布条件的影响训练结果

表 3 样本数量、样本分布条件的影响

样本量/类朴素贝叶斯分布	训练轮次	训练集 acc	验证集 acc	训练集 loss
100/是	200	0.994	1.000	0.0181
200/是	200	0.991	1.000	0.0187
100/否	200	0.981	1.000	0.0664
200/否	200	0.978	0.975	0.0751

样本分布的影响：当样本符合类朴素贝叶斯分布时，训练集 $\text{acc} \geq 0.99$ 、 $\text{loss} \leq 0.0187$ 、验证集 $\text{acc}=1.0$ ，说明逻辑回归在数据满足线性可分或近似线性分布（如类朴素贝叶斯分布）时，模型拟合效率高、泛化稳定性强，且参数少。反之，逻辑回归性能略有下降，证明逻辑回归对数据分布敏感，依赖“特征与标签线性相关”假设

样本量的影响：类朴素贝叶斯分布下，逻辑回归在较小样本量的情况下均能保持极高准确率和泛化率，但当样本量较大时其训练时间、性能消耗增加，效果可能下降。

（二）两种求解方法和正则化的影响

在该项中选择样本数量为 200，分布为类朴素贝叶斯分布。




图 5-8 求解方法和正则化的影响训练结果

表 4 求解方法和正则化的影响

求解方法/正则化	训练轮次	训练集 acc	验证集 acc	训练集 loss
梯度下降/否	200	0.991	1.000	0.0187
梯度下降/是	200	0.991	1.000	0.0235
牛顿法/否	14	0.991	1.000	0.0132
牛顿法/是	10	0.991	1.000	0.0215

求解方法的影响：牛顿法显著降低了逻辑回归的训练轮次，说明其在解决该类问题上的高效性，但考虑到其求解方法需要计算 Hessian 矩阵，当样本特征映射至高维后，求解复杂度将极大增加，这是其局限性。

正则化的影响：逻辑回归加入正则化后 acc 不变、loss 略升，说明其过拟合控制能力有限，正则化仅通过惩罚参数抑制复杂度，无法从模型结构上避免过拟合。

（三）模型在真实数据上的分类表现

表 5 真实数据集上的表现

求解方法/正则化	训练轮次	训练集 acc	验证集 acc	训练集 loss
梯度下降/否	200	0.985	0.971	0.0418
梯度下降/是	200	0.985	0.971	0.0461
牛顿法/否	17	0.991	0.985	0.0183
牛顿法/是	10	0.993	0.985	0.0355

可以发现，模型在真实数据集上仍有较好的表现，且与自建数据集上的表现相近，验证了模型的正确性。

四、 结论

样本符合类朴素贝叶斯分布时，模型训练精度高（ $\text{acc} \geq 0.991$ ）、损失低（ $\text{loss} \leq 0.0187$ ）、泛化能力强（验证集 $\text{acc} \geq 1.0$ ）；而非该分布下，模型性能显著下降，且样本量增大会进一步加剧拟合难度与泛化能力下滑。

牛顿法求解效率与性能均优于梯度下降，无论在类朴素贝叶斯分布数据还是真实数据中，牛顿法的收敛轮次仅为梯度下降的 $1/10$ - $1/20$ ，且能实现更高的训练精度与更低的训练损失，是逻辑回归模型更高效的求解方法。

正则化在实验条件下作用有限：在样本符合类朴素贝叶斯分布（无过拟合）或真实数据（轻微过拟合风险）中，正则化仅轻微提高训练损失，对验证集泛化精度无影响；仅在牛顿法+真实数据的组合中，正则化小幅提升训练精度，但整体未改变模型核心性能。

五、 参考文献

- [1]（美）SHELDON AXLER 著；杜现坤，刘大艳，马晶译. 线性代数应该这样学 第3版[M]. 北京：人民邮电出版社, 2016.10.
- [2]周志华著. 机器学习[M]. 北京：清华大学出版社, 2016.01.
- [3]谢文睿，秦州编著. 机器学习公式详解[M]. 北京：人民邮电出版社, 2021.03.
- [4]李航著. 统计学习方法 第2版[M]. 北京：清华大学出版社, 2019.05.